Instituto Federal de Educação, Ciência e
Tecnologia de Mato Grosso - IFMT
Campus Cuiabá – Cel. Octayde Jorge da Silva

Processamento Digital de Imagens

Prof. Dr. Thiago Statella
thiagostatella.weebly.com
thiago.statella@cba.ifmt.edu.br

Sumário

1. Introdução
2. Resolução de sistemas sensores
3. Formação de imagens
4. Transformações de imagem
5. Distorções radiométricas
6. Distorções geométricas
7. Realce de imagens
8. Filtros espaciais de suavização
9. Realce de bordas
10. Binarização
11. Filtragem no domínio da frequência
12. Restauração de imagens
13. Classificação de imagens
14. Processamento de imagens coloridas
15. Performance do sensor
16. Morfologia Matemática

Bibliografia

Na elaboração deste material foram utilizadas as seguintes bibliografias:

- DURINI, D. Fundamental Principals of Photosensing. In: DURINI, D. **High Performance Silicon Imaging.** Cambridge: Ed. Elsevier, 2014. p. 1-24.
- Gomes, J.; VELHO, L. **Computação Gráfica - Volume 1**. IMPA - Instituto de Matemática Pura e Aplicada, Rio de Janeiro, RJ-Brasil, 1998. 323p.
- Gonzalez, R. C.; Woods, R. E. **Processamento de Imagens Digitais**. 3ª ed. Edgard Blucher Ltda. 2010.
- HOWELL, S. B. **Handbook of CCD Astronomy**. 2 ed. Cambridge: Cambridge University Press, 2006.
- JANESICK, J. R. **Scientific charge-coupled devices**. Washington: SPIE, 2001.
- JANSEN, R. A. **Astronomy with Charged Coupled Devices**. AST 598 Instrumentation and Data Reduction Course. ASU, 2006.
- Jensen, J. R. **Sensoriamento Remoto do ambiente: uma perspectiva em recursos terrestres**. São José dos Campos – SP: Parêntese, 2009.
- McANDREW, A. **Introduction to Digital Image Processing with Matlab**. Thomson Learning: Victoria, Melborne, 2004. 509p. (ISBN 0-534-40011-6).
- Moreira, Maurício Alves. **Fundamentos do Sensoriamento Remoto e Metodologias de aplicação.** SJ dos Campos: INPE. 2001.
- Novo, Evlyn M. L. de Moraes. **Sensoriamento Remoto: princípios e aplicações.** Edgard Blucher Ltda. 2011.
- Richards, John A. **Remote Sensing Digital Image Analysis: a introduction**. Springer, 1999.
- SCHOTT, J.R. **Remote Sensing: the image chain approach**. 2 ed. New York: Oxford University Press, 2007.

13 Classificação de imagens

Espaço Multiespectral e Classes Espectrais

Maneira mais eficiente de representar os dados multiespectrais (espaço vetorial com *n* dimensões)

Agrupamentos de pixels com uma certa similaridade

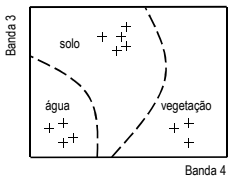

13 Classificação de imagens

Quando muitos vetores de medições são locados num espaço multiespectral, referentes a um mesmo tipo de cobertura da terra, mas em diferentes localizações, o mais provável é que formem um agrupamento localizado, ou uma nuvem de pontos. Este fenômeno é resultado da aleatoriedade da natureza, decorrente por exemplo: da variação na tonalidade das folhas, condições atmosféricas, ruídos no sensor, etc.

Definidas as bandas espectrais que fornecem uma melhor discriminação, espera-se que os pixels se agrupem no espaço multiespectral e que cada um dos grupos formados corresponda a um tipo diferente de cobertura da terra.

13 Classificação de imagens

Classes de Informação X Classes Espectrais

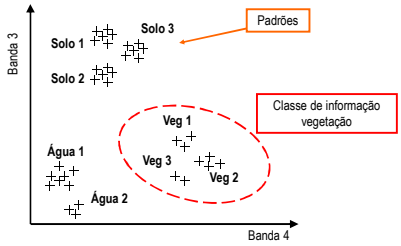

13 Classificação de imagens

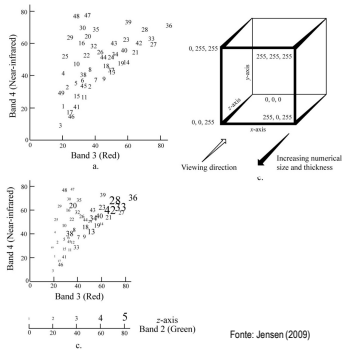

(a) Agrupamentos de pixels no espaço multiespectral; (b) Aumento do tamanho e espessura dos números de acordo com o tamanho do agrupamento; (c) Introdução de uma nova bando ao espaço multiespectral, formando um cubo.

Fonte: Jensen (2009)

13 Classificação de imagens

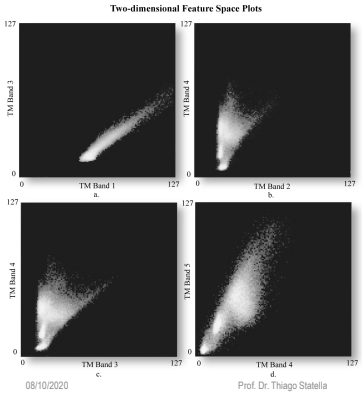

Histogramas bidimensionais de 4 pares de cenas Landsat: (a) bandas 1 e 3; (b) bandas 2 e 4; (c) bandas 3 e 4; (d) bandas 4 e 5. Quanto mais claro um dado pixel é, maior é a quantidade de pixels dentro da cena com aquela combinação de tons de cinza (que servem de coordenas no histograma bidimensional).

Fonte: Jensen (2009)

13 Classificação de imagens

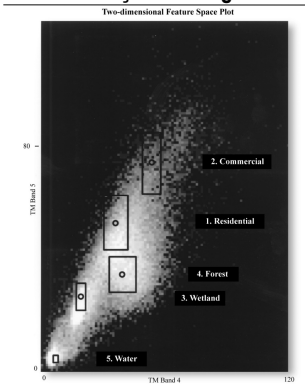

Estatísticas de 5 classes de treinamento no espaço multiespectral formado pelas bandas 4 e 5 do Landsat TM, mostradas como paralelepípedos. Os limites superiores e inferiores de cada paralelepípedo são dados por ±1σ da média das amostras.

Fonte: Jensen (2009)

13 Classificação de imagens

Pixels (vetores) → Padrões

Classes espectrais → Reconhecimento de Padrões → Rotulação

Um sistema de reconhecimento de padrões faz uma série de medições em um "dicionário de padrões".

13 Classificação de imagens

Funções discriminantes: uma interpretação geométrica do reconhecimento de padrões

Espaço multiespectral bidimensional

São formadas 3 regiões de decisão

Limites de decisão

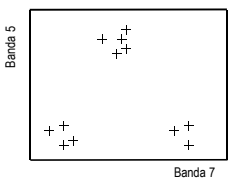

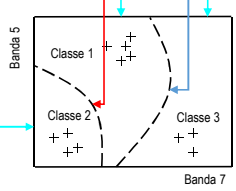

13 Classificação de imagens

Suponha *m* classes → *m* funções de *x*

$g_1(x), g_2(x), \ldots, g_m(x)$ funções discriminantes

Se $g_i(x)$ apresentar um valor maior que qualquer outra função discriminante, *x* será um ponto da *i*-ésima região de decisão.

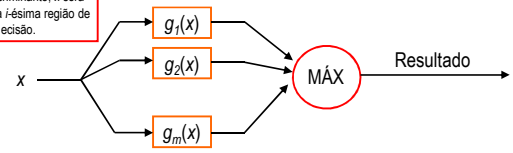

13 Classificação de imagens

Exemplo: regra de classificação

Seja w_i a i-ésima classe, determinar $x \in w_i$ se, e somente se, $g_i(x) \geq g_j(x)$, para todo j = 1, 2, 3,..., m.

Uma vez que $g_2 > g_1$ para toda a reta, classificar os pontos:

$$x_a = \begin{bmatrix} 1/2 \\ 1 \end{bmatrix} \quad x_b = \begin{bmatrix} 3/2 \\ 3/2 \end{bmatrix} \quad x_c = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Obs.: Na maioria das vezes as funções discriminantes são definidas usando informações obtidas a partir de um conjunto de padrões de treinamento.

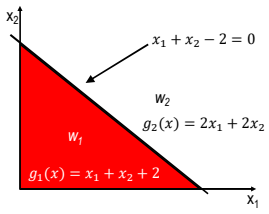

13 Classificação de imagens

Classificação não-supervisionada: meio pelo qual os pixels de uma imagem são associados a classes espectrais, sem que haja um conhecimento prévio da existência ou do nome das classes.

Classificação supervisionada: há o conhecimento prévio das classes de informação e as funções discriminantes são derivadas de um processo de treinamento.

13 Classificação de imagens

A classificação pode ainda ser feita pixel a pixel ou por regiões. Na classificação supervisionada por pixel, parâmetros estatísticos das classes de informação, obtidos na etapa de treinamento, serão empregados para rotular cada pixel. Na classificação por pixel não-supervisionada, algum método de agregamento baseado em medidas de similaridade deve ser empregado para formar classes espectrais que, posteriormente, serão identificadas pelo usuário.

A classificação por regiões requer o prévio particionamento da imagem em regiões. Exemplos de métodos de segmentação de regiões são o método de Crescimento de Regiões e de Detecção de Bacias. Na classificação supervisionada por regiões, o usuário deve cumprir a etapa de treinamento em que regiões representativas das classes de informação são selecionadas como amostras de treinamento. No caso não-supervisionado, as regiões são associadas a classes espectrais que devem ser, posteriormente, identificadas pelo usuário.

13 Classificação de imagens

No processo de treinamento, o usuário especifica vetores representativos de cada classe de informação que se deseja rotular na imagem. Essas amostras serão utilizadas como um "dicionário de padrões" no momento da atribuição de cada pixel a uma classe específica.

13 Classificação de imagens | 13.1 Classificação supervisionada

Etapas da classificação supervisionada:

1) Decidir a quantidade de classes de informação consideradas na segmentação da imagem;
2) Escolher amostras representativas de cada classe no processo de treinamento;
3) Utilizar as amostras de treinamento para estimar parâmetros estatísticos de cada classe de informação. Estes parâmetros serão utilizados pelas funções discriminantes para segmentar o espaço multiespectral;
4) Utilizar o classificador treinado para rotular os pixels da imagem em classes de informação.

13 Classificação... | 13.1 Classificação supervisionada | 13.1.1 Por pixel

Método de Máxima Verossimilhança (pixel)

É o método mais comum de classificação supervisionada. Esse critério é baseado em uma caracterização estatística do conjunto de dados analisados e no teorema de Bayes.

Cada pixel é rotulado como pertencente à classe para a qual a sua probabilidade de pertencimento é maior.

O método de máxima verossimilhança assume que os dados de treinamento seguem uma distribuição normal (gaussiana).

Dados de treinamento com distribuição *n*-modal provavelmente representam classes diferentes que deveriam ser tratadas como tal.

13 Classificação... | 13.1 Classificação supervisionada | 13.1.1 Por pixel

Método de Máxima Verossimilhança (pixel)

Informações estatísticas sobre as amostras de treinamento são obtidas pelo cálculo da função densidade de probabilidade. Exemplo para o caso unidimensional abaixo, com uma classe de treinamento (floresta) na banda *k*. A distribuição (a) pode ser aproximada pela curva em (b).

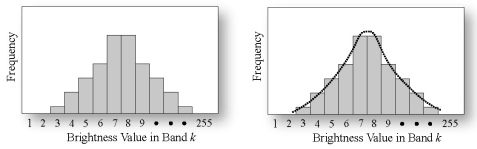

a. Histogram (data frequency distribution) of forest training data in a single band *k*.

b. Data distribution approximated by a normal probability density function.

Fonte: Jensen (2009)

13 Classificação... | 13.1 Classificação supervisionada | 13.1.1 Por pixel

Método de Máxima Verossimilhança (pixel)

A equação da função densidade de probabilidade para uma dada classe wi é obtida pela equação:

$$\hat{p}(x \mid w_i) = \frac{1}{(2\pi)^{\frac{1}{2}}\hat{\sigma}_i} \exp\left[-\frac{1}{2}\frac{(x-\hat{\mu}_i)^2}{\hat{\sigma}_i^{\,2}}\right]$$

Em que *x* é um valor de brilho, μi e σi são a média e o desvio padrão dos dados de treinamento da classe wi. Portanto, apenas média e variância de cada conjunto de amostras precisam ser armazenadas para construir suas funções de probabilidade.

Método de Máxima Verossimilhança (pixel)

Revendo alguns fundamentos de probabilidade e estatística

$p(\vec{x})$ Em SR, ***x*** é um pixel vetor, logo, $p(x)$ é a probabilidade de que um pixel possa ser encontrado na posição ***x*** no espaço multiespectral.

$p(\vec{x}|y)$ Probabilidade de que ***x*** ocorra dado um *y* especificado (prob. condicional).

$p(\vec{x}|w_i)$ Probabilidade de encontrar um pixel vetor na posição ***x*** no espaço multiespectral dada uma classe de interesse w_i, isto é, a probabilidade de que um pixel da classe w_i exista na posição ***x***. Em SR, w_i (i = 1, 2, ..., M) são os conjuntos completos de classes espectrais.

$p(w_i)$ Probabilidade de que a classe w_i ocorra na imagem (ou de que um pixel selecionado aleatoriamente pertencerá à classe w_i).

$p(\vec{x}|w_i)p(w_i)$ Probabilidade de que um pixel na posição ***x*** no espaço multiespectral seja um pixel de w_i. É conhecida como a probabilidade conjunta de ***x*** e w_i. É a probabilidade de que um pixel ocorra na posição ***x*** e que ele seja de w_i (diferente da probabilidade de que um pixel ocorra na posição ***x*** dado que seja da classe w_i).

$p(\vec{x}) = \sum_{i=1}^{M} p(\vec{x}|w_i)p(w_i)$ Probabilidade de que um pixel de qualquer classe possa ser encontrado na posição ***x***.

$p(\vec{x}, w_i) = p(\vec{x}|w_i)p(w_i)$ * Probabilidade conjunta de ***x*** e w_i.

$p(w_i, \vec{x}) = p(w_i|\vec{x})p(\vec{x})$ ** Probabilidade conjunta de w_i e ***x***, ou seja, de que eles existam juntos. É a prob. condicional que expressa a possibilidade de que a classe seja w_i, dado que estamos examinando um pixel ***x*** no espaço multiespectral.

$p(w_i,x)$ e $p(x,w_i)$ são iguais, portanto, de * e ** temos

$p(w_i|\vec{x}) = p(\vec{x}|w_i)p(w_i)/p(\vec{x})$ **Teorema de Bayes**.

A distribuição Normal de Probabilidade

As probabilidades condicionais de classes $p(x|w_i)$ em SR frequentemente são assumidas como pertencendo a uma distribuição normal de probabilidade. No caso de um espaço espectral unidimensional isso é descrito como:

$$p(x|w_i) = (2\pi)^{-1/2}\sigma_i^{-1}exp\left(\frac{-(x-m_i)^2}{2\sigma_i^2}\right)$$

Em que:

x = pixel candidato (variável espectral)
m_i = valor médio de x com σ_i sendo seu desvio padrão

$\sigma_i^2 = \frac{1}{q_i - 1}\sum_{j=1}^{q_i}(x_j - m_i)^2$ Variância da distribuição, com q_i sendo o número de pixels para a classe w_i e x_j é a j-ésima amostra.

13 Classificação... | 13.1 Classificação supervisionada | 13.1.1 Por pixel

A distribuição Normal de Probabilidade

No caso multivariado ***x*** passa a ser um vetor, bem como ***m***, e a variância deve ser modificada para levar em conta não apenas a multidimensionalidade mas também para incluir o efeito da correlação entre as bandas espectrais. Este papel é atendido pela matriz de covariância Σ:

$$\sum_i = \frac{1}{q_i - 1} \sum_{j=1}^{q_i} \left[(\vec{x}_j - \vec{m}_i)(\vec{x} - \vec{m}_i)^t \right]$$

Assim, para um número N de dimensões espectrais, a probabilidade condicional das classes no caso multivariado fica:

$$p(\vec{x}|w_i) = (2\pi)^{-N/2} |\Sigma_i|^{-1/2} \exp\left(-\frac{1}{2} (\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i) \right)$$

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Classificação por Máxima Verossimilhança

a) Classificação de Bayes

Sejam as classes espectrais de uma imagem representadas por w_i, i=1,...M. Determinar a que classe um pixel vetor numa posição ***x*** pertence é o mesmo que determinar a probabilidade condicional:

$$p(w_i|\vec{x}), \qquad i = 1, \ldots M$$

O vetor posição é um vetor coluna dos valores de brilho do pixel. Ele descreve a posição do pixel no espaço multiespectral. A probabilidade $p(w_i|\mathbf{x})$ fornece a verossimilhança para alocar o pixel ***x*** na classe w_i. A classificação é feita, então, de acordo com

$$\vec{x} \in w_i \;\; se \;\; p(w_i|\vec{x}) > p(w_j|\vec{x}) \;\; para\, todo\, j \neq i$$

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Apesar de sua simplicidade, $p(w_i|\mathbf{x})$ é desconhecida. Mas suponhamos que haja um número suficiente de dados de treinamento disponível para cada classe. Estes dados podem ser usados para estimar a distribuição de probabilidade para uma determinada classe, o que descreve a chance de encontrar um pixel da classe w_i numa posição ***x***, por exemplo: $p(\mathbf{x}|w_i)$. Existirão tantas $p(\mathbf{x}|w_i)$ quantas forem as classes, ou seja, para um dado pixel ***x*** no espaço multiespectral, será calculado um conjunto de probabilidades que fornecerão a relativa verossimilhança desse pixel pertencer a uma das classes disponíveis.

A probabilidade desejada $p(w_i|\mathbf{x})$ (desconhecida) e a probabilidade $p(\mathbf{x}|w_i)$, obtida com os dados de treinamento, são relacionadas pelo teorema de Bayes:

$$p(w_i|\vec{x}) = p(\vec{x}|w_i) p(w_i) / p(\vec{x})$$

Em que $p(w_i)$ é a probabilidade de que a classe w_i ocorra na imagem.

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

b) Regra de decisão da Máxima Verossimilhança

$p(w_i|\vec{x})$ É desconhecida

Suficientes dados de treinamento disponíveis para cada classe → Estimativa da distribuição de probabilidade para um tipo de cobertura, o que descreve a chance de encontrar um pixel da classe w_i na posição *x*. → $p(\vec{x}|w_i)$

$p(w_i|\vec{x})$ e $p(\vec{x}|w_i)$ são relacionadas pelo teorema de Bayes

↓

$$p(w_i|\vec{x}) = p(\vec{x}|w_i) p(w_i) / p(\vec{x})$$

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Usando o Teorema de Bayes a regra de decisão passa a ser:

$$\vec{x} \in w_i \;\; se \;\; p(\vec{x}|w_i)p(w_i) > p(\vec{x}|w_j)p(w_j) \;\; para\, todo\, j \neq i$$

Como $p(\mathbf{x})$ é um fator comum nos dois termos do Teorema de Bayes, o mesmo pode ser removido. Além disso, em aplicações em que se assume serem iguais $p(w_i)$ e $p(w_j)$ os mesmos podem ser desconsiderados também.

Por conveniência, a equação anterior pode ser reescrita:

$$g_i = \ln(p(\vec{x}|w_i)p(w_i))$$

$$g_i = \ln p(\vec{x}|w_i) + \ln p(w_i) \text{ ***}$$

Então: $\vec{x} \in w_i \; se \; g_i(\vec{x}) > g_j(\vec{x}) \; para\, todo\, j \neq i$

$g_i(x)$ e $g_j(x)$ são as **funções discriminantes** do MaxVer

Regra de decisão generalizada usada na classificação pelo método de máxima verossimilhança

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

c) Modelos para classes normais multivariadas

Neste estágio, assume-se que as distribuições de probabilidade para cada classe estão na forma de modelos normais multivariados. Essa é mais uma suposição que uma propriedade que possa ser demonstrável sobre a natureza espectral das classes de informação. Entretanto, ela conduz a consideráveis simplificações matemáticas e, além disso, é uma distribuição para a qual as propriedades estatísticas da forma multivariada são bem conhecidas.

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Assumindo-se agora que serão utilizadas N bandas espectrais e incorporando a função densidade de probabilidade normal multivariada à ***, temos:

$$p(\vec{x}|w_i) = (2\pi)^{-N/2}|\Sigma_i|^{-1/2}\exp\left(-\frac{1}{2}(\vec{x}-\vec{m}_i)^t\Sigma_i^{-1}(\vec{x}-\vec{m}_i)\right)$$

Em que m e Σ são o vetor de média e matriz de covariância dos dados na classe w_i. O termo $-N/2*\ln(2\pi)$ (resultante de $(2\pi)^{-N/2}$) é comum a todas funções discriminantes g_i e pode ser ignorado na forma final da função discriminante:

$$g_i(\vec{x}) = \ln p(w_i) - \frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\vec{x}-\vec{m}_i)^t\Sigma_i^{-1}(\vec{x}-\vec{m}_i)$$

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Frequentemente, o analista não dispõe de informações confiáveis sobre $p(w_i)$ (probabilidade a priori das classes), então assume-se que sejam iguais. Isto leva a uma nova simplificação:

$$g_i(\vec{x}) = -\ln|\Sigma_i| - (\vec{x}-\vec{m}_i)^t\Sigma_i^{-1}(\vec{x}-\vec{m}_i) \;\; *$$

A implementação da regra de decisão de máxima verossimilhança envolve a utilização da equação * acima na relação:

$$\vec{x} \in w_i \; se \; g_i(\vec{x}) > g_j(\vec{x}) \; para\, todo\, j \neq i$$

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

d) Superfícies de decisão

Classes espectrais → Regiões no espaço multiespectral onde suas funções discriminantes assumem os maiores valores → As regiões podem ser separadas pelas superfícies onde as *f* discriminantes são iguais

$g_i(\vec{x}) - g_j(\vec{x}) = 0$ ← Superfície de decisão

$(\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i)$ → Função quadrática de ***x*** → Superfícies de decisão: parábolas, círculos e elipses

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

e) Limiares

Está implícito no desenvolvimento anterior que os pixels que definem os pontos do espaço multiespectral serão classificados como pertencentes a uma das classes disponíveis w_i desconsiderando o fato de que alguns dos pixels têm probabilidade bastante reduzida de pertencerem a uma dada classe.

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

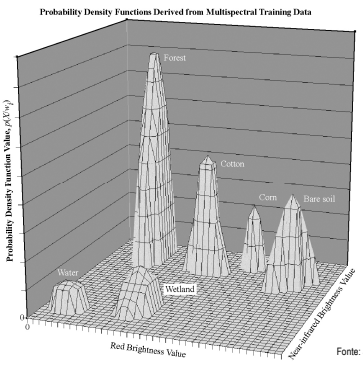

Função densidade de probabilidade bivariada para seis classes de informação arranjadas no espaço vermelho-infravermelho próximo. Note como as funções de distribuição aparentam ter comportamento normal (aparência de sino). O eixo vertical está associado com a probabilidade de um vetor X de medidas de um pixel desconhecido ser membro de uma das classes.

Separação: Ok

Fonte: Jensen (2009)

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

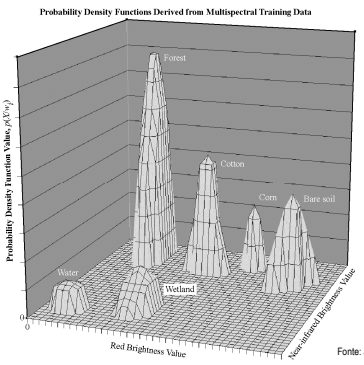

Em outras palavras, se um vetor de medidas desconhecido possui valores de brilho de maneira que ele esteja localizado dentro da classe *região alagada* (wetland), então ele tem uma grande probabilidade de ser um pixel de região alagada.

Separação: Ok

Fonte: Jensen (2009)

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Separação: problemática

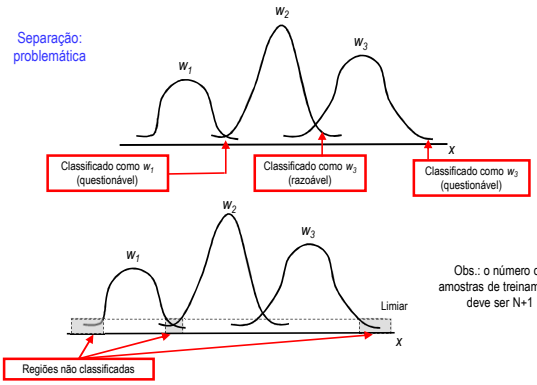

Obs.: o número de amostras de treinamento deve ser N+1

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

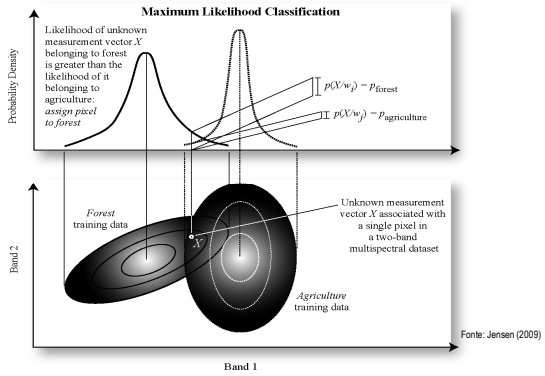

Fonte: Jensen (2009)

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

Os problemas apresentados na figura anterior podem ocorrer quando duas classes têm um certo grau de sobreposição, ou quando os pixels estão no final da uma função de distribuição. Os padrões que apresentam, para todas as classes, uma probabilidade abaixo de um certo limiar não serão classificados.

Na prática, os limiares são aplicados às funções discriminantes e não às distribuições de probabilidade, já que estas últimas não são realmente calculadas. Com a incorporação de um limiar T à regra de decisão de máxima verossimilhança ficará:

13 Classificação... | 13.1 Classificação... | 13.1.1 Por pixel | 13.1.1.1 MaxVer

O próximo passo é verificar como o limiar T pode ser estimado. A partir das discussões feitas até o momento, uma classificação é aceitável se:

$$\ln p(w_i) - \frac{1}{2}\ln|\Sigma_i| - \frac{1}{2}(\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i) > T_i \qquad (1)$$

Ou seja:

$$(\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i) < -2T_i - \ln|\Sigma_i| + 2p(w_i) \qquad (2)$$

O termo ao lado esquerdo de (2) tem uma distribuição χ^2 com N graus de liberdade, se assume-se que **x** tenha distribuição normal. N é o número de bandas do espaço multiespectral. A partir de tabelas de χ^2 pode-se determinar o valor:

$$(\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i)$$

Abaixo do qual haverá um certo número de pixels que não serão classificados.

Um exemplo de como isso pode ser usado considera a necessidade de escolher um limiar para os dados de quatro bandas espectrais TM Landsat, para o qual 95% de todos os pixels de uma classe deverão ser classificados (5% dos pixels para cada classe serão rejeitados). A tabela χ^2 indica que, para 95% de confiança, todos os pixels devem ter um valor de χ^2 maiores que 9,488. Assim, a equação (2) ficará:

$$T_i = -4{,}744 - \frac{1}{2}\ln|\Sigma_i| + \ln p(w_i)$$

O que pode ser calculado a partir do conhecimento da probabilidade a priori (das classes, $p(w_i)$) e da matriz de covariância da i-ésima classe espectral.

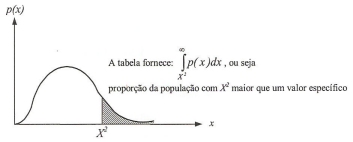

Número de pixels de treinamento requeridos para cada classe

O número de amostras de treinamento deve ser o suficiente para permitir uma estimativa confiável dos elementos do vetor média e a determinação da matriz de covariância. Para um espaço multiespectral de N dimensões serão requeridas N+1 amostras para evitar que a matriz de covariância seja singular (determinante igual a zero). Para que as expressões da função discriminante possam ser encontradas é importante dispor-se de tantos pixels de treinamento quanto possível.

Classificação por Distância Mínima da Média (pixel)

O bom desempenho do método de máxima verossimilhança depende da quantidade de dados de treinamento disponíveis para estimação da função densidade de probabilidade das classes. Quando o número de amostras de treinamento é limitado, é melhor recorrer a métodos que não utilizem a matriz de covariância das classes. Nestas situações o classificador mais adequado seria o de distância mínima da média, no qual os dados de treinamento são usados para estimar apenas o valor médio das classes e a classificação é feita alocando o pixel à classe de média mais próxima.

O algoritmo de distância mínima da média é mais rápido que o de máxima verossimilhança. Entretanto, pelo fato de não usar os dados da matriz de covariância, ele é menos flexível. Na classificação por máxima verossimilhança, cada classe é modelada por uma função multivariada normal, o que permite avaliar a dispersão dos dados em uma dada direção espectral. Visto que a covariância não é usada na distância mínima da média, os modelos de classe são simétricos no domínio espectral. Classes alongadas, no entanto, não podem ser modeladas e, quando elas ocorrem, a utilização do algoritmo de classificação de máxima verossimilhança é mais adequada.

a) Função discriminante

Supondo-se que $\boldsymbol{m}_i$, i = 1, 2, ..., **M** sejam as médias das **M** classes, determinadas a partir de dados de treinamento, e $\boldsymbol{x}$ seja o pixel vetor a ser classificado. Um conjunto de distâncias Euclidianas, ao quadrado, é definido na forma vetorial como:

$$d(\vec{x}, \vec{m}_i)^2 = (\vec{x} - \vec{m}_i)^T (\vec{x} - \vec{m}_i)$$

A expansão do produto resulta em:

$$d(\vec{x}, \vec{m}_i)^2 = \vec{x} \cdot \vec{x} - 2 \cdot \vec{m}_i \cdot \vec{x} + \vec{m}_i \cdot \vec{m}_i$$

A classificação é feita com base no seguinte critério:

$$\vec{x} \in \omega_i \; se \; d(\vec{x}, \vec{m}_i)^2 < d\left(\vec{x}, \vec{m}_j\right)^2 \; para \; todo \; j \neq i$$

Note que $\vec{x} \cdot \vec{x}$ é comum para todas as distâncias e por isso pode ser removido da expressão. Além disso, pode-se inverter o sinal da equação anterior, de modo que a regra de classificação para a técnica da distância mínima da média seja expressa como:

$$\vec{x} \in \omega_i \; se \; g_i(\vec{x}) > g_j(\vec{x}) \; para \; todo \; j \neq i$$

Em que:

$$g_i(\vec{x}) = 2 \cdot \vec{m}_i \cdot \vec{x} - \vec{m}_i \cdot \vec{m}_i$$

b) Superfícies de decisão

As superfícies de decisão que separam classes adjacentes no espaço multiespectral caracterizam-se pela natureza idêntica de suas funções discriminantes para essas classes. Assim, a superfície de decisão entre a i-ésima e j-ésima classes é definida por:

$$g_i(\vec{x}) - g_j(\vec{x}) = 0$$

Ou seja:

$$2 \cdot \left(\vec{m}_i - \vec{m}_j\right) \cdot \vec{x} - \left(\vec{m}_i \cdot \vec{m}_i - \vec{m}_j \cdot \vec{m}_j\right) = 0$$

O que define uma superfície de decisão linear, a qual define um hiperplano, quando representada em mais de três dimensões. Em contraste com a classificação de máxima verossimilhança, nas quais as superfícies de decisão são quadráticas e mais flexíveis, as superfícies de decisão da distância mínima da média são lineares e menos flexíveis.

b) Limiares

Limiares são aplicados na distância mínima da média para assegurar que a proximidade de um pixel em relação a uma dada classe esteja dentro de uma distância prescrita para esta classe. Frequentemente, um limiar de distância é aplicado de acordo com um determinado número de desvios-padrão para a média da classe.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.2 Distância mínima da média

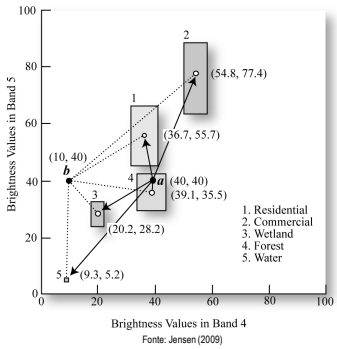

Fonte: Jensen (2009)

Classificação dos pixels *a* e *b* pelo método da distância mínima da média. O pixel *a* é classificado como pertencente à classe 4, e o pixel *b* será classificado como pertencente à classe 3.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.3 Mahalanobis

O classificador de Mahalanobis (pixel)

Quando são utilizadas probabilidades a priori iguais para as classes, a função discriminante do classificador de máxima verossimilhança pode ser considerada como uma medida quadrática de distância, desde que o sinal da equação seja invertido. Assim, pode-se definir:

$$d(\vec{x}, \vec{m}_i) = \ln|\Sigma_i| - (\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i)$$

E classificar os pixels com base na menor distância *d*, como no caso do classificador de mínima distância da média. Nessas situações o classificador de máxima verossimilhança pode ser considerado um classificador de distância mínima que é sensível à direção e dispersão das classes.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.3 Mahalanobis

Consideremos agora uma situação em que todas as covariâncias das classes são iguais, ou seja, $\Sigma_i = \Sigma_j$, para todo *i*. Neste caso, o termo $\ln|\Sigma_i|$ não é mais discriminante para as classes e pode ser ignorado, de modo que a medida de distância ficará reduzida a:

$$d(\vec{x}, \vec{m}_i) = (\vec{x} - \vec{m}_i)^t \Sigma_i^{-1} (\vec{x} - \vec{m}_i)$$

Esta função discriminante define um classificador que utiliza a distância de Mahalanobis, que é a medida de distância de aplicação também geral, como a Euclidiana.

A vantagem do classificador de Mahalanobis sobre o procedimento de máxima verossimilhança é que ele é mais rápido e ainda conserva um certo grau de sensibilidade à direção das classes, através da matriz de covariância.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.4 Paralelepípedo

Método do Paralelepípedo (pixel)

É o classificador mais elementar no qual, em princípio, todo o treinamento é feito a partir da análise dos histogramas dos componentes espectrais individuais dos dados de treinamento disponíveis.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.4 Paralelepípedo

Os limites inferior e superior do histograma são identificados e usados para descrever o intervalo de valores de brilho para cada componente que caracteriza uma dada classe. Juntos, os intervalos definidos em todas as componentes descrevem uma figura multidimensional, ou um paralelepípedo. Quando, na classificação, os pixels ficam inseridos dentro do paralelepípedo, eles são classificados como pertencentes à classe que define aquele paralelepípedo.

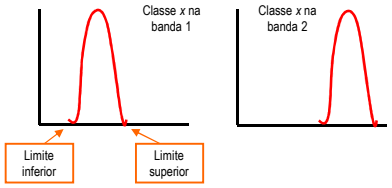

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.4 Paralelepípedo

Restrições: 1) ocorrência de vazios, de modo que pixels que caem nessas regiões não são classificados; 2) em regiões onde há sobreposição de classes (onde há correlação entre classes) não é possível separar os pixels.

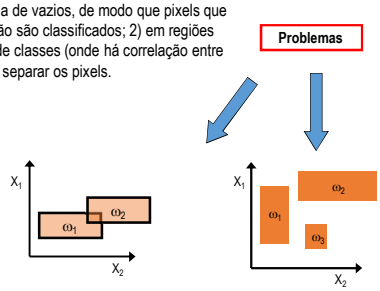

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.4 Paralelepípedo

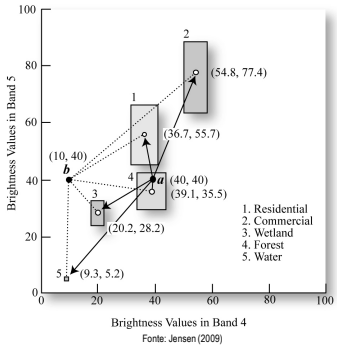

Fonte: Jensen (2009)

Classificação dos pixels *a* e *b* pelo método do paralelepípedo. O pixel *a* é classificado como pertencente à classe 4, mas o pixel *b* não será classificado.

13 Classificação... | 13.1... | 13.1.1 Por pixel | 13.1.1.5 Pós-processamento

Pós processamentos (pixel)

Uma imagem classificada apresenta, geralmente, uma aparência salpicada em função da inerente variabilidade espectral de uma cena encontrada por um classificador quando este é aplicado pixel a pixel. Por exemplo, muitos pixels encontrados em um campo de milho podem ser classificados como soja, ou vice-versa. Nestas situações é desejável homogeneizar a classificação, a fim de mostrar apenas a classe dominante. Uma maneira de fazer isso é a aplicação de filtros de moda.

13 Classificação... | 13.1... | 13.1.2 Por região

Segmentação de imagens

Na classificação por regiões é necessário fazer a segmentação da imagem em regiões com características espectrais similares. Um método clássico de segmentação de imagens é o de Crescimento de Regiões.

Crescimento de Regiões

A abordagem básica é começar com um conjunto de pontos "semente" e, a partir daí, fazer as regiões crescerem anexando a cada semente aqueles pixels vizinhos que têm propriedades predefinidas semelhantes às das sementes (como intervalos específicos de intensidade ou cor).

13 Classificação... | 13.1... | 13.1.2 Por região

Crescimento de Regiões

Seja f(x,y) a imagem de entrada, S(x,y) um arranjo contendo sementes (números 1 indicando o local das sementes e 0 preenchendo os demais locais) e Q uma propriedade a ser avaliada em cada posição (x,y). O algoritmo básico do crescimento de regiões baseia-se na conectividade 8 e pode ser estabelecido como segue:

13 Classificação... | 13.1... | 13.1.2 Por região

1) Encontrar todos os componentes conectados em S e erodir cada componente conectado a um pixel; rotular todos os pixels encontrados com o número 1. Todos os demais pixels recebem 0.
2) Formar uma imagem f_Q que, em um par de coordenadas (x,y), deixe $f_Q(x,y) = 1$ se a imagem de entrada satisfaz a propriedade determinada, Q, nestas coordenadas; caso contrário, deixe $f_Q(x,y) = 0$.
3) Digamos que g seja uma imagem formada anexando a cada semente em S todos os pontos rotulados com o número 1 em f_Q que estão na vizinhança-8 dessa semente.
4) Rotular cada componente conectado em g com uma etiqueta diferente de região. Esta é a imagem segmentada obtida pelo crescimento de região.

13 Classificação... | 13.1... | 13.1.2 Por região

Exemplo: Segmentar a região com defeito em uma solda (região escura em (a)) a partir de uma imagem de raios X. A região com defeitos aparece clara (fissuras e porosidades horizontais).

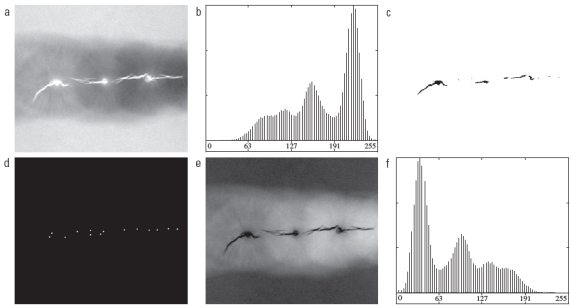

Gonzalez e Woods, 2010

13 Classificação... | 13.1... | 13.1.2 Por região

A primeira etapa é encontrar pontos sementes. No exemplo, isto é feito de maneira semiautomática, através da binarização da imagem (c) com base no histograma e posterior erosão morfológica (d).

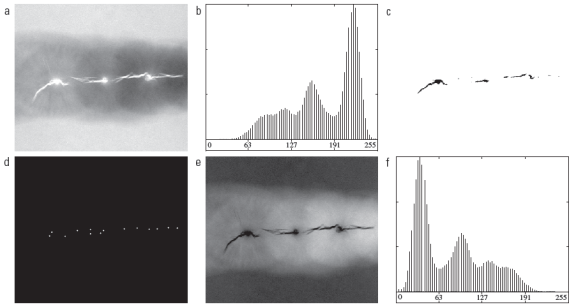

Gonzalez e Woods, 2010

13 Classificação... | 13.1... | 13.1.2 Por região

Em seguida, temos que especificar uma propriedade. Neste exemplo, queremos adicionar a cada semente todos os pixels que: a) sejam 8-conectados a esta semente; e b) sejam semelhantes em intensidade a ela. Utilizando diferenças de intensidade como uma medida de similaridade, nossa propriedade aplicada em cada posição (x,y) é:

$$Q=\begin{cases} Verdadeiro & \text{Se a diferença absoluta das intensidades entre o pixel e a semente for} \leq T \\ Falso & \text{Caso contrário} \end{cases}$$

Em que T é um limiar estabelecido.

13 Classificação... | 13.1... | 13.1.2 Por região

A figura (e) mostra o valor absoluto da diferença entre as imagens (c) e (a). A imagem na figura (e) contém todas as diferenças necessárias para calcular a propriedade em cada posição (x,y). A figura (f) mostra o histograma correspondente.

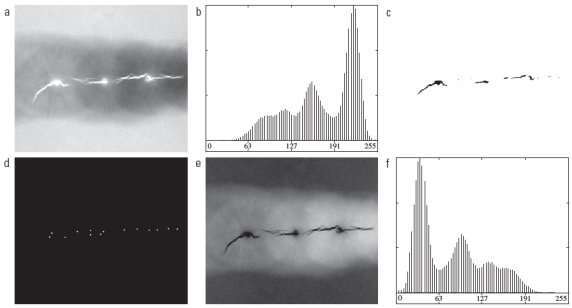

Gonzalez e Woods, 2010

13 Classificação... | 13.1... | 13.1.2 Por região

É preciso um limiar que será aplicado à imagem (e) para estabelecer a similaridade. Escolhemos T = 68 (tom de cinza). A imagem (g) mostra o resultado da limiarização. Os pontos pretos são posições nas quais a propriedade foi Verdadeira (isto é, diferença absoluta entre pixel e semente foi menor ou igual a T). Como se nota, os pontos na região boa da solda (região mais escura na imagem original) não cumpriram a propriedade, então não serão incluídos no resultado final.

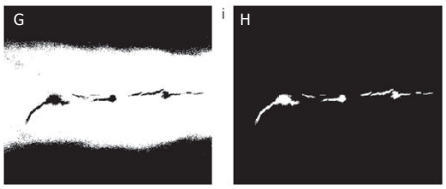

Gonzalez e Woods, 2010

13 Classificação... | 13.1... | 13.1.2 Por região

Os pontos na região exterior serão considerados como candidatos pelo algoritmo de crescimento de regiões. No entanto, na etapa 3, serão rejeitados porque não estão na vizinhança 8 de cada semente. O resultado do crescimento de regiões é mostrado na imagem (h). Observe que o uso da conectividade era uma exigência fundamental neste caso. Na etapa 4 foi utilizado o mesmo valor de rotulação para todas as regiões (apenas por conveniência).

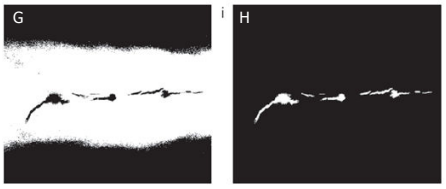

Gonzalez e Woods, 2010

13 Classificação... | 13.1... | 13.1.2 Por região

Após a segmentação de imagens, para executar a classificação supervisionada por regiões, é preciso cumprir a etapa de treinamento. A classificação por regiões pode seguir o esquema implementado no *software* Spring, que consiste nos seguintes passos:

1. **Definição do limiar:** o usuário define um limiar de aceitação, dado em percentagem. Este limiar, por sua vez, define uma distância usada para medir a separabilidade estatística entre um par de classes espectrais, de forma que todas regiões pertencentes a uma dada classe estão distantes da classe por uma medida inferior à especificada. Quanto maior o limiar, maior esta distância e, consequentemente, menor será o número de classes detectadas pelo algoritmo.

13 Classificação... | 13.1... | 13.1.2 Por região

2. **Detecção das classes:** As regiões são ordenadas em ordem decrescente de área e inicia-se o procedimento para agrupá-las em classes. Serão tomados como parâmetros estatísticos de uma classe (média e matriz de covariância), os parâmetros estatísticos da região de maior área que ainda não tenha sido associada a classe alguma. Em seguida, associa-se a esta classe todas regiões cuja métrica empregada seja inferior ao limiar de aceitação. Esta fase repete-se até que todas regiões tenham sido associadas a alguma classe.

13 Classificação... | 13.1... | 13.1.2 Por região

3. **Competição entre classes:** O passo 2 consiste basicamente na detecção de classes, sendo um processo sequencial que pode favorecer as classes que são detectadas em primeiro lugar. Com objetivo de eliminar este favorecimento, executa-se a competição entre classes. Esta competição consiste em reclassificar todas as regiões. Um parâmetro estatístico (média de cada classe) é então recalculado. O processo repete-se até que a média das classes não se altere (convergência). Ao término, todas regiões estarão associadas a uma classe definida pelo algoritmo.

13 Classificação... | 13.1... | 13.1.2 Por região | 13.1.2.1 Bhattacharyya

O algoritmo implementado no Spring para classificação supervisionada por regiões usa a distância de **Bhattacharyya**. A medida da distância de Bhattacharyya é usada para medir a separabilidade estatística entre um par de classes espectrais. Ou seja, mede a distância média entre as distribuições de probabilidades de classes espectrais. Ela é dada por (Jensen, 2004):

$$B(i,j) = \frac{1}{8}(\vec{m}_i - \vec{m}_j)^t \left(\frac{\Sigma_i + \Sigma_j}{2}\right)^{-1} (\vec{m}_i - \vec{m}_j) + \frac{1}{2}\ln\left[\frac{\left|\frac{\Sigma_i + \Sigma_j}{2}\right|}{\sqrt{|\Sigma_i| \cdot |\Sigma_j|}}\right]$$

Em que *i* e *j* são classes espectrais; m_i e m_j são os vetores de médias das classes *i* e *j*; e Σ_i e Σ_j são as matrizes de covariâncias das classes.

13 Classificação... | 13.2 Classificação não-supervisionada

Medidas de similaridade e critérios de agregamento

O agregamento consiste em agrupar os pixels no espaço multiespectral. Pixels pertencendo a um grupo em particular são, portanto, espectralmente similares. Para quantificar esse relacionamento é preciso estabelecer uma medida de similaridade. Normalmente são usadas medidas simples de distância.

13 Classificação... | 13.2 Classificação não-supervisionada

Sendo x_1 e x_2 dois pixels cuja similaridade deve ser testada, então a distância Euclidiana entre eles será:

$$d(x_1, x_2) = \|x_1 - x_2\|$$
$$d(x_1, x_2) = [(x_1 - x_2)^t \cdot (x_1 - x_2)]^{1/2}$$
$$d(x_1, x_2) = \left[\sum_{i=1}^{N} (x_{1i} - x_{2i})^2\right]^{1/2}$$

Em que N é o número de componentes espectrais.

A distância Interponto entre eles será:

$$d(x_1, x_2) = \sum_{i=1}^{N} |x_{1i} - x_{2i}|$$

13 Classificação... | 13.2 Classificação não-supervisionada

Um critério comum que serve de indicativo da qualidade do agregamento é a soma dos quadrados dos erros SQE:

$$SQE = \sum_{C_i} \sum_{x \in C_i} (x - m_i)^t \cdot (x - m_i)$$

$$SQE = \sum_{C_i} \sum_{x \in C_i} \|x - m_i\|^2$$

Em que m_i é a média dos *i*-ésimos agregamentos e $x \in c_i$ é o padrão designado para aquele grupo. O somatório externo permite calcular a distância acumulada de cada padrão ao centro de seu respectivo grupo, para cada um dos grupos individualmente. Os valores obtidos são, então, somados para todos os grupos. Se o SQE for pequeno, as distâncias dos padrões ao centro do grupo são todas pequenas e o agregamento formado é considerado aceitável.

A Otimização Iterativa (médias migrantes) em Algoritmos de Agregamento (pixel)

O método de agregamento de otimização iterativa, também chamado técnica de médias migrantes, é essencialmente um algoritmo de *Isodata* (*Iterative Self-Organizing Data Analysis Technique*). Ele se baseia na estimativa do SQE para distribuições iniciais dos vetores de atributos dos pixels nos agregamentos candidatos, e então os move de um grupo para outro a fim de reduzir o SQE.

A Otimização Iterativa (médias migrantes) em Algoritmos de Agregamento (pixel)

Algoritmo

1) O processo é iniciado pela seleção de C pontos no espaço multiespectral, os quais servirão como centros iniciais dos agregamentos candidatos:

$$\hat{m}_i \ , \ i = 1,2,\ldots,C$$

A seleção dos para este estágio é arbitrária, considerando a premissa de que dois deles não podem ser iguais. Para evitar a geração de grupos anômalos é adequado espaçar uniformemente as médias dos agregamentos iniciais sobre todo o conjunto de dados. Antes de escolher os o número de grupos C deve ser especificado pelo usuário.

A Otimização Iterativa (médias migrantes) em Algoritmos de Agregamento (pixel)

Algoritmo

2) A localização *x* de cada pixel na imagem a ser segmentada é examinada, e o pixel é indicado para o grupo candidato mais próximo. Esta indicação pode ser feita com base na distância Euclidiana ou Interponto.
3) São calculados novos conjuntos de médias para o agregamento formado no passo 2. Estas novas médias são designadas como:

$$m_i \ , \ i = 1,2,\ldots,C$$

4) Se para todo *i*, o procedimento é finalizado. Caso contrário, é redefinido como sendo o valor atual , e o processo retorna ao passo 2.

Outras maneiras de finalizar o processo, além do que foi estabelecido no passo 4, podem ser:

i) Estabelecer um limar T que controla a porcentagem de pixels que trocaram de grupo numa determinada iteração. Se esta quantidade de pixels for menor que o limiar T, então o processo encerra-se.
ii) Estabelecer um limite máximo M de iterações. Ao atingir este limite o processo é encerrado.

13 Classificação... | 13.2 ... | 13.2.1 Por pixel | 13.2.1.1 Médias migrantes

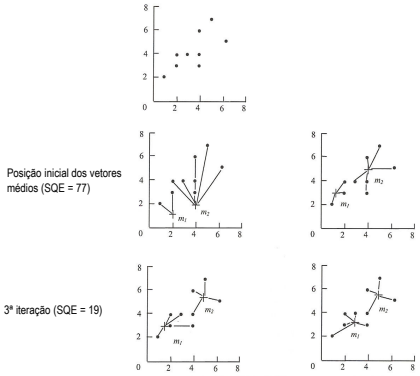

13 Classificação... | 13.2 ... | 13.2.1 Por pixel | 13.2.1.1 Médias migrantes

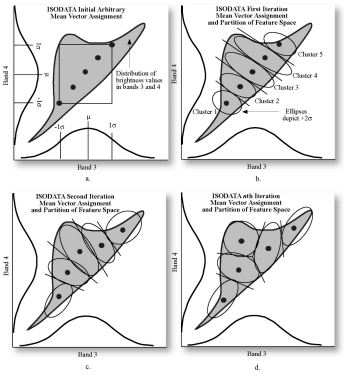

a) Distribuição inicial de 5 vetores médios hipotéticos usando $\pm 2\sigma$ como pontos inicial e final nas duas bandas consideradas; b) na 1ª iteração cada pixel candidato é comparado a cada vetor médio e rotulado como pertencente ao grupo cuja distância até o vetor médio foi a menor;
c) 2ª iteração em que novos vetores de média são calculados. Fusão e divisão de grupos podem ocorrer a partir desta etapa; d) O processo continua até atingir o critério de parada.

Fonte: Jensen (2009)

13 Classificação... | 13.2 ... | 13.2.1 Por pixel | 13.2.1.1 Médias migrantes

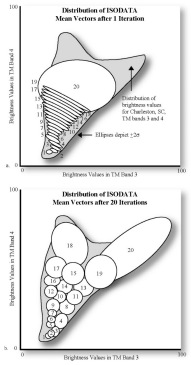

a) Distribuição de 20 vetores de média após uma iteração usando as bandas 3 e 4 do Landsat/TM;
b) Distribuição dos 20 vetores de média após 20 iterações.

Fonte: Jensen (2009)

13 Classificação... | 13.2 ... | 13.2.1 Por pixel | 13.2.1.1 Médias migrantes

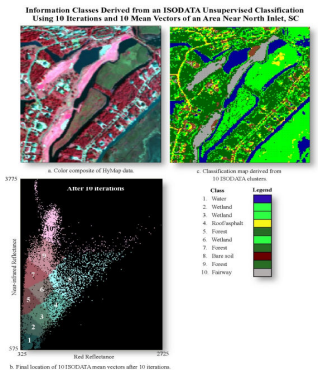

Classificação baseada em ISODATA.

Fonte: Jensen (2009)

13 Classificação... | 13.2 ... | 13.2.1 Por pixel | 13.2.1.1 Médias migrantes

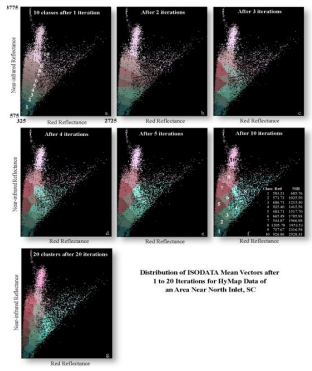

Classificação baseada em ISODATA.

Fonte: Jensen (2009)

13 Classificação... | 13.2 Classificação não-supervisionada | 13.2.2 Por região

Fusões e Eliminações

Após o agregamento, ou mesmo para um dado estágio intermediário, os agregamentos podem ser examinados para a verificação de:

a) Se alguns grupos contiverem poucos pontos, ou se ocorrerem grupos inexpressivos (quando não fornecem estimativas estatísticas aceitáveis), tais grupos podem ser eliminados;
b) Se alguns grupos estão tão próximos que representam uma divisão desnecessária ou impraticável dos dados, então eles podem ser fundidos.

13 Classificação... | 13.2 Classificação não-supervisionada | 13.2.2 Por região

Separação de grupos alongados

Outro critério que pode ser inserido no algoritmo de isodata é a separação de agregamentos alongados em dois novos grupos. Este procedimento pode ser feito pré-especificando um desvio padrão, além do qual um agregamento seria dividido em partes iguais.

13 Classificação... | 13.2 Classificação não-supervisionada | 13.2.2 Por região

No final do agregamento os pixels de um dado grupo são associados a um mesmo símbolo, indicando que eles pertencem à mesma classe espectral. A análise de um mapa de clusters permite que uma classificação seja feita. Se o conjunto de pixels de uma dada categoria for identificado como um tipo específico de cobertura da terra, então todos os pixels com a mesma categorização podem ser associados àquela classe.

ISOSEG (regiões)

No caso da classificação não-supervisionada por regiões, pode-se aplicar o esquema implementado no *software* Spring, que usa o algoritmo ISOSEG. Os passos do algoritmo são os mesmos descritos na classificação supervisionada por regiões, exceto que, neste caso, utiliza-se a distância de Mahalanobis para definir a separabilidade entre classes:

1. **Definição do limiar:** o usuário define um limiar de aceitação, dado em percentagem. Este limiar, por sua vez, define a distância de Mahalanobis usada para medir a separabilidade estatística entre um par de classes espectrais, de forma que todas regiões pertencentes a uma dada classe estão distantes da classe por uma medida inferior à especificada. Quanto maior o limiar, maior esta distância e, consequentemente, menor será o número de classes detectadas pelo algoritmo.

2. **Detecção das classes:** As regiões são ordenadas em ordem decrescente de área e inicia-se o procedimento para agrupá-las em classes. Serão tomados como parâmetros estatísticos de uma classe (média e matriz de covariância), os parâmetros estatísticos da região de maior área que ainda não tenha sido associada a classe alguma. Em seguida, associa-se a esta classe todas regiões cuja distância de Mahalanobis seja inferior ao limiar de aceitação. Esta fase repete-se até que todas regiões tenham sido associadas a alguma classe.

3. **Competição entre classes:** O passo 2 consiste basicamente na detecção de classes, sendo um processo sequencial que pode favorecer as classes que são detectadas em primeiro lugar. Com objetivo de eliminar este favorecimento, executa-se a competição entre classes. Esta competição consiste em reclassificar todas as regiões. Um parâmetro estatístico (média de cada classe) é então recalculado. O processo repete-se até que a média das classes não se altere (convergência). Ao término, todas regiões estarão associadas a uma classe definida pelo algoritmo.

Estimativa da precisão da classificação

Estimar a exatidão de uma classificação envolve comparar os resultados da classificação com áreas testes de identidade conhecida, as quais apresentam tipos de cobertura da terra obtidos a partir de dados de referência.

Áreas testes são representativas dos tipos de cobertura da terra, diferentes e consideravelmente mais extensas que as áreas de treinamento.

13 Classificação... | 13.3 Precisão da classificação

Não existe um consenso quanto ao cálculo do número de amostras necessárias para estimar a exatidão da classificação. Van Genderen et al. (1978), como exemplo, usaram estatística bimodal para produzir a seguinte tabela:

Exatidão da classificação	Tamanho mínimo da amostra por categoria
95%	60
90%	30
85%	20
80%	15
60%	10
50%	5

Van Genderen, J.L., Lock, B.F., Vass, P.A., 1978. Remote Sensing: Statistical Testing of Thematic Map Accuracy. *Remote Sensing of Environment* 3, 7-14.

13 Classificação... | 13.3 Precisão da classificação

A escolha das amostras pode ser feita segundo um padrão *aleatório*, *sistemático*, ou alguma destas duas abordagens *estratificada por categoria*.

A exatidão na classificação pode ser estimada através de uma matriz de confusão ou de erros. Esta é uma matriz quadrada contendo um conjunto de números dispostos em linhas e colunas, os quais expressam o número de pixels associados a um tipo específico de cobertura da terra, em relação ao verdadeiro tipo de cobertura, verificado em campo ou interpretado a partir de fotografias aéreas. As colunas normalmente se referem aos dados de referência (tomados como corretos) e as linhas indicam as classes definidas através dos dados de SR. Os valores da diagonal principal da matriz representam, então, os pixels que foram corretamente classificados e a razão entre a soma desses valores pelo número total de pixels classificados resulta na exatidão global da classificação EG:

$$EG = \frac{\sum x_{ii}}{N}$$

Em que x_{ii} são os valores da matriz na linha *i* com a coluna *i* e *N* é o número total de observações.

13 Classificação... | 13.3 Precisão da classificação

Outra alternativa é utilizar o índice Kappa, uma técnica multivariada discreta, que considera todos os valores da matriz de confusão. O índice Kappa (K) é uma medida da concordância real (indicada pelos elementos diagonais da matriz de confusão) menos a concordância por chance (indicada pelo produto total da linha e coluna), ou seja, é uma medida do quanto a classificação está de acordo com os dados de referência. O índice Kappa pode ser calculado através da seguinte equação:

$$K = \frac{N \cdot \sum_{i=1}^{L} x_{ii} - \sum_{i=1}^{L} x_{i+} \cdot x_{+i}}{N^{2} - \sum_{i=1}^{L} x_{i+} \cdot x_{+i}}$$

Em que *L* é o número de linhas da matriz (número de classes), x_{ii} são os valores da matriz na linha *i* com a coluna *i* , x_{i+} é a soma da linha *i*, x_{+i} é a soma da coluna *i* e *N* é o número total de observações.

13 Classificação... | 13.3 Precisão da classificação

Abaixo, exemplo de uma matriz de confusão. Os valores da diagonal principal são aqueles classificados corretamente. As informações marginais de linha e coluna permitem calcular os erros de omissão/inclusão. Erros de omissão ocorrem quando pixels pertencentes a uma classe de interesse são alocados em outras classes. Na tabela abaixo, estes erros são mostrados ao final de cada coluna: 30%, 8% e 11% para as classes A, B e C.

		Classes de referência			Total	Erro de inclusão/classe
		A	B	C		
Classes temáticas	A	35 (70%)	2 (5%)	2 (4%)	39	4/39=0,10
	B	10 (20%)	37 (93%)	3 (7%)	50	13/37=0,35
	C	5 (10%)	1 (2%)	41 (89%)	47	6/47=0,13
Nº pixels de referência		50	40	46	136	
Erro de omissão/classe		15/50=0,30	3/40=0,08	5/46=0,11		

13 Classificação... | 13.3 Precisão da classificação

Erros de inclusão ocorrem quando pixels de outras classes são associados à classe de interesse e são apresentados no final de cada linha: 10%, 35% e 13% para as classes A, B e C.

		Classes de referência			Total	Erro de inclusão/classe
		A	B	C		
Classes temáticas	A	35 (70%)	2 (5%)	2 (4%)	39	4/39=0,10
	B	10 (20%)	37 (93%)	3 (7%)	50	13/37=0,35
	C	5 (10%)	1 (2%)	41 (89%)	47	6/47=0,13
Nº pixels de referência		50	40	46	136	
Erro de omissão/classe		15/50=0,30	3/40=0,08	5/46=0,11		

13 Classificação... | 13.3 Precisão da classificação

Calculando a exatidão global e índica Kappa temos:

EG = 0,831 e
K = 0,747.

		Classes de referência			Total	Erro de inclusão/classe
		A	B	C		
Classes temáticas	A	35 (70%)	2 (5%)	2 (4%)	39	4/39=0,10
	B	10 (20%)	37 (93%)	3 (7%)	50	13/37=0,35
	C	5 (10%)	1 (2%)	41 (89%)	47	6/47=0,13
Nº pixels de referência		50	40	46	136	
Erro de omissão/classe		15/50=0,30	3/40=0,08	5/46=0,11		

13 Classificação... | 13.3 Precisão da classificação

Embora o índice Kappa seja muito utilizado na avaliação da exatidão de mapeamento, não existe uma fundamentação teórica para recomendar quais os níveis mínimos aceitáveis deste índice numa classificação. Entretanto, a Tabela abaixo apresenta níveis de desempenho da classificação para o valor de Kappa, normalmente aceitos pela comunidade científica (Figueiredo, G.C., Vieria, C.A.O., 2007. Estudo do comportamento dos índices de Exatidão Global, Kappa e Tau, comumente usados para avaliar a classificação de imagens do sensoriamento remoto. *In: XIII SBSR*, 5755-5762).

Índice Kappa	Desempenho
< 0	Péssimo
$0 < K \leq 0,20$	Ruim
$0,20 < K \leq 0,40$	Razoável
$0,40 < K \leq 0,60$	Bom
$0,60 < K \leq 0,80$	Muito Bom
$0,80 < K \leq 1,00$	Excelente